# Autoescalado en Kubernetes

KEEPCODING
Tech School

# Conceptos de escalado

- Escalado de PODs
- Escalado de Cluster



# Tipos de autoescalado en Kubernetes

- Autoescalado horizontal de PODs (**HPA**) - Funcionalidad interna / estándar de Kubernetes
- Autoescalado horizontal de cluster (nodos) - Requiere integración con Cloud para provisionar nodos.
- Autoescalado vertical de PODs (**VPA**) - Funcionalidad externa
- Autoescalado vertical de cluster (nodos) - Funcionalidad externa



# HPA (Horizontal POD Autoscaling)

KEEPCODING
Tech School

# Auto-escalado horizontal de Pods

- También llamado HPA
- Nos permite de forma dinámica aumentar y disminuir las réplicas de un Deployment.
- apiVersions
  - v1 solo soporta autoescalado en base a consumo de CPU.
  - v2 ha sido beta hasta 1.23. Ya es GA, permite cualquier métrica del metrics-server.
- Definimos umbral, y valores mínimo y máximos
- Es necesario definir resources en los pods.



https://kubernetes.io/docs/tasks/run-application/horizontal-pod-autoscale-walkthrough/

# Auto-escalado horizontal de Pods

- Demo disponible aqui:

```
~$ kubectl autoscale deploy hpa-example --cpu-percent=20 --min=2 --max=20
~$ kubectl run -i --tty load-generator -rm --image=busybox /bin/sh

~# while true; do wget -q -O- http://hpa-example; done

~$ kubectl get hpa
```

```
apiVersion: autoscaling/v1
kind: HorizontalPodAutoscaler
metadata:
  name: hpa-example
spec:
  maxReplicas: 20
  minReplicas: 2
  scaleTargetRef:
    apiVersion: extensions/v1beta1
    kind: Deployment
    name: hpa-example
  targetCPUUtilizationPercentage: 20
```



https://kubernetes.io/docs/tasks/run-application/horizontal-pod-autoscale-walkthrough/

# Cluster Autoscaling

KEEPCODING
Tech School

# Autoescalado de Cluster

- Es un escalado horizontal de nodos del cluster (aumentar / disminuir nodos iguales).
- Cuándo nos quedamos sin recursos, la manera de añadir más es añadir más nodos o añadir nodos más grandes.
- Mediante el componente "**cluster-autoscaler**" se notifica al API de gestión de infraestructura la creación de un nuevo nodo.
- Hay que instalarlo aparte, requiere integración con la cloud / infraestructura.
- Funcionamiento:
  - **Si un POD se va a crear y no quedan recursos disponibles, el scheduler notifica la necesidad de un nodo nuevo.**
  - **Cuándo el nodo nuevo se crea, entonces el scheduler crea el POD en el nuevo nodo.**
  - **También funciona hacia abajo, si sobran recursos, el cluster-autoscaler se encarga de eliminar nodos.**



# Autoescalado de Cluster

- En GKE

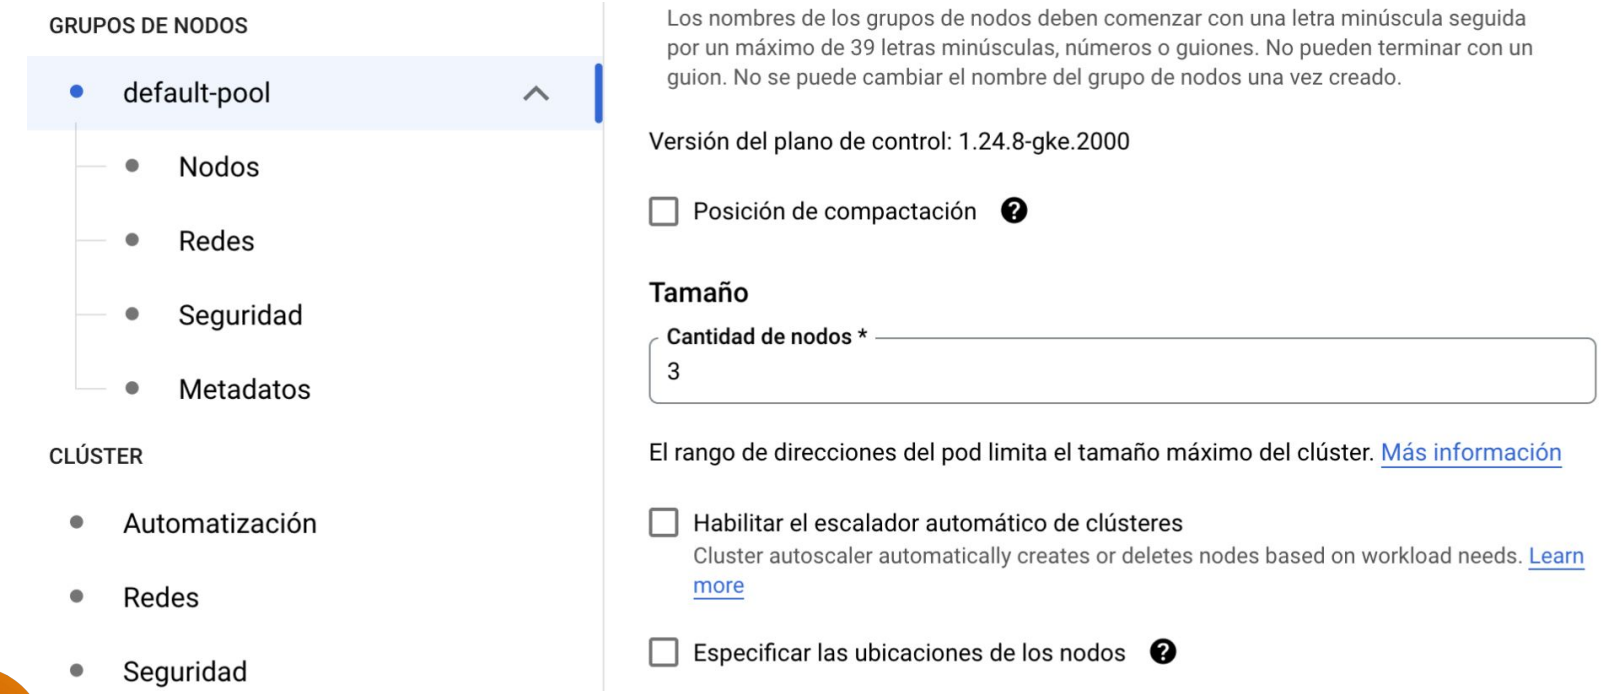

# Node auto-provisioning (GKE)

- Si un POD requiere unas características de un nodo que no existe nos permite provisionar node-pools con nodos que las satisfaga.
- No está limitado sólo a CPU y RAM, si no a cualquier requisito hardware (GPU, Local SSD, TPU)
- Si un node-pool deja de ser utilizado, GKE lo eliminará.
- Podemos marcar como un node-pool como “manual” para que no lo elimine.
- Podemos marcar un node-pool creado por nosotros como “automático” para que si deja de usarse, GKE lo elimine.
- Con esto conseguimos una **experiencia de autoescalado vertical en cuanto a nodos.**



https://cloud.google.com/kubernetes-engine/docs/how-to/node-auto-provisioning

# Node auto-provisioning

- En GKE

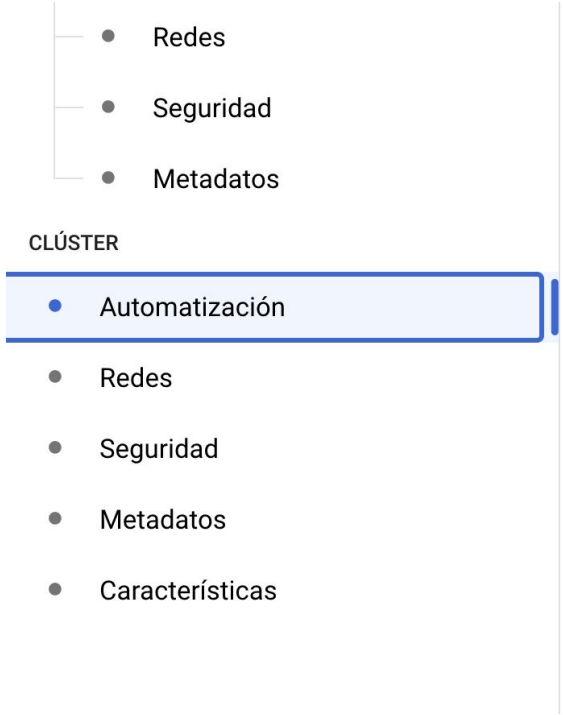

# Vertical Pod Autoscaling

KEEPCODING
Tech School

# Auto-escalado vertical de PODs

- No es funcionalidad estándar en Kubernetes, hay que instalarla / configurarla de forma externa.
- Background
  - Nosotros normalmente estableceremos manualmente unos valores de requests y limits.
  - Puede que no “acertemos” con los valores adecuados de primeras.
  - Si queremos ajustar de forma óptima estos valores, es necesario ajustar correctamente los resources asignados, y puede ser costoso.
- VPA nos puede ayudar a encontrar estos valores y ajustarlos.
- Puede ayudar a reducir el mantenimiento y a usar los recursos de la manera más eficiente.



# Funcionamiento de VPA

- En GKE se puede activar la funcionalidad.
  - Guía / how-to
  - Referencia
- Puede funcionar en 2 modos: “recomendación” y “automático”.
- Modo recomendación:
  - Únicamente nos hará un análisis de los consumos y nos dará una recomendación que podemos seguir.
- Modo automático:
  - Igualmente hará el análisis, pero adicionalmente se encargará de establecer los nuevos límites recreando los Pods (requiere reinicio)



https://cloud.google.com/kubernetes-engine/docs/how-to/vertical-pod-autoscaling

# VPA manual

```
~$ gcloud beta container clusters create [CLUSTER_NAME] --enable-vertical-pod-autoscaling
~$ gcloud beta container clusters update [CLUSTER-NAME] --enable-vertical-pod-autoscaling
```

```yaml
apiVersion: apps/v1
kind: Deployment
metadata:
  name: my-rec-deployment
spec:
  replicas: 2
  template:
    metadata:
      labels:
        app: my-rec-deployment
    spec:
      containers:
      - name: my-rec-container
        image: nginx
```

```yaml
apiVersion: autoscaling.k8s.io/v1beta2 # OUTDATED ;)
kind: VerticalPodAutoscaler
metadata:
  name: my-rec-vpa
spec:
  targetRef:
    apiVersion: "apps/v1"
    kind:       Deployment
    name:       my-rec-deployment
  updatePolicy:
     updateMode: "Off"
```

```
~$ kubectl get vpa my-rec-vpa --output yaml
```



https://cloud.google.com/kubernetes-engine/docs/how-to/vertical-pod-autoscaling

# VPA Automático

```yaml
apiVersion: apps/v1
kind: Deployment
metadata:
  name: my-auto-deployment
spec:
  replicas: 2
  template:
    metadata:
      labels:
        app: my-auto-deployment
    spec:
      containers:
      - name: my-container
        image: k8s.gcr.io/ubuntu-slim:0.1
        resources:
          requests:
            cpu: 100m
            memory: 50Mi
        command: ["/bin/sh"]
         args: ["-c", "while true; do timeout 0.5s yes >/dev/null; sleep 0.5s; done"]
```

```yaml
apiVersion: autoscaling.k8s.io/v1beta2
kind: VerticalPodAutoscaler
metadata:
  name: my-rec-vpa
spec:
  targetRef:
    apiVersion: "extensions/v1beta1"
    kind:       Deployment
    name:       my-rec-deployment
  updatePolicy:
     updateMode: "Auto"
```

```
~$ kubectl get vpa my-vpa --output yaml
```



https://cloud.google.com/kubernetes-engine/docs/how-to/vertical-pod-autoscaling

# Ejercicios autoescalado

KEEPCODING
Tech School

# Autoscaling - 1

Configurar un deployment que auto escale en número de PODs con un umbral, un número mínimo y un número máximo que tú elijas.



# Autoscaling - 2

Configura un clúster con “cluster-autoscaler”.
Crea muchos PODs con resources y comprueba que funciona.



# Autoscaling - 3

Crea un clúster con node auto provisioning.
Crea algún POD con más recursos disponibles de lo que hay en cualquier nodo actual.
Comprueba que se crea un nuevo nodo con las características requeridas.



# Autoscaling - 4

Crea un POD de Nginx. Asigna 1 CPU y 1GBi de RAM.
Configura Vertical Pod Autoscaler
Comprueba que ajusta automáticamente los recursos del POD.



# KEEPCODING

## Tech School

Madrid | Barcelona | Bogotá